

# 홍익지기 프로젝트 종합 개요

## 프로젝트 소개

홍익지기는 천공 스승님의 정법 가르침을 기반으로 한 AI 챗봇입니다. 사용자가 질문을 입력하면 정법 강의 내용을 바탕으로 통찰력 있는 답변을 제공하여, 자기 이해 증진과 홍익인간 이념 실현을 돕습니다.

## 프로젝트 목표

- 정법 강의 내용을 쉽게 접근할 수 있는 대화형 인터페이스 제공
- 일상 생활에서 마주하는 다양한 어려움에 대한 깊이 있는 답변 제공
- 자기 성찰과 내면의 성장을 도모하며 홍익인간의 삶을 실현하도록 안내
- 정법 관련 지식을 효과적으로 전달하고 개인화된 조언 제공
- 관련 주제와 강의를 추천하여 심층적인 이해 도모

## 타겟 사용자

- 정법 강의에 관심이 있는 사람들
- 삶의 방향과 내면의 성장을 추구하는 사람들
- 현대 사회의 문제와 해결책에 대한 통찰을 구하는 사람들
- 홍익인간 이념에 공감하는 사람들

## 사용자 요구사항

- 정법 관련 질문에 대한 정확하고 깊이 있는 답변
- 개인적인 고민이나 질문에 대한 맞춤형 조언
- 정법 강의 내용 중 관련 있는 부분을 쉽게 찾아볼 수 있는 기능
- 직관적이고 사용하기 쉬운 인터페이스
- 출처가 명확한 답변과 추가 학습 자료 추천

## 현재 기술 구성

### 백엔드 시스템

- 언어 모델: OpenAI GPT-4o 기반 (LangChain 통합)
- 벡터 데이터베이스: ChromaDB (정법 강의 내용 저장)
- 임베딩 모델: text-embedding-ada-002 (OpenAI)
- 프로그래밍 언어: Python 3.8+
- 웹 프레임워크: Flask, Gradio

### 프론트엔드

- 웹 인터페이스: Gradio 기반 UI
- CLI: 명령줄 인터페이스 제공

## 프로젝트 진행 과정

### 개발 타임라인

1. 기획 및 설계 단계 (초기)
  - 프로젝트 목표 및 범위 정의
  - 디렉토리 구조 설계
  - 기술 스택 선정 (Python, LangChain, ChromaDB 등)
2. 데이터 수집 및 처리 (1단계)
  - 정법 강의 텍스트 데이터 수집
  - 문서 로더 및 텍스트 정규화 모듈 개발
  - 문서 청크 분할 알고리즘 구현
  - 처리된 문서 데이터셋 구축
3. 태그 시스템 개발 (2단계)
  - 태그 스키마 설계 (7개 주요 카테고리 정의)
  - 패턴 기반 자동 태깅 시스템 구축
  - 태그 추출기 및 태그 분석기 모듈 구현
  - 태그 기반 검색 최적화
4. QA 생성 및 벡터화 (3단계)
  - 질문-답변 쌍 자동 생성 파이프라인 개발
  - 생성된 QA 데이터 검증 및 정제
  - 벡터 저장소 구축 및 임베딩 생성
  - 유사도 검색 알고리즘 구현
5. 챗봇 인터페이스 개발 (4단계)
  - 콘솔 기반 CLI 인터페이스 구현
  - Gradio 기반 웹 인터페이스 개발
  - 관련 질문 추천 시스템 통합
  - 사용자 인터페이스 디자인 및 개선

### Two-Stage 파이프라인 구축

- 스테이지 1: 문서 처리 (문서 로드 → 청크화 → 태깅)
- 스테이지 2: 벡터 저장소 구축 (청크 병합 → QA 생성 → 벡터화)

### 문서 처리 흐름

정법 문서 → 청크화 → 태깅 → 병합 → QA 생성 → 벡터 저장소 → 챗봇 응답 → 사용자 UI

### 질의응답 흐름

사용자 질문 → 임베딩 변환 → 벡터 검색 → 관련 문서 검색 → LLM 답변 생성 → 사용자 응답

### 주요 데이터 경로

| 단계 | 경로                                      | 설명                          |
|----|-----------------------------------------|-----------------------------|
| 1  | data/<br>jungbub_teachings/             | 원본 텍스트 문서 저장<br>(txt/pdf 등) |
| 2  | data/tag_data/<br>input_chunks/         | 청크화된 문서들                    |
| 3  | data/tag_data/<br>auto_tagged/          | 자동 태깅된 문서                   |
| 4  | data/processed/<br>jungbub_dataset.json | 병합된 정제 결과                   |
| 5  | data/qa/<br>jungbub_qa_dataset.js<br>on | 질문-답변 QA 쌍                  |
| 6  | data/vector_store/                      | Chroma 벡터 저장소 (검<br>색용)     |

## 핵심 모듈 도식

1. 문서 처리 모듈: 원본 텍스트 → 청크화 → 메타데이터 추출
2. 태깅 모듈: 패턴 매칭 → 키워드 추출 → 태그 할당
3. QA 생성 모듈: 청크 분석 → 질문 생성 → 답변 매핑
4. 검색 모듈: 벡터 검색 → 태그 기반 필터링 → 관련성 순위화
5. 응답 생성 모듈: 검색 결과 통합 → 컨텍스트 구성 → LLM 응답 생성

## 현재 구현된 핵심 기능

1. 정법 기반 질의응답: 사용자 질문에 대해 정법 강의를 기반으로 한 답변 제공
2. 출처 제공: 답변 생성 시 참조한 정법 강의 출처 표시
3. 관련 질문 추천: 현재 질문과 관련된 추가 질문 제안
4. 태그 시스템: 정법 가르침을 주제별로 분류하여 검색 정확도 향상
5. 태그 기반 검색: 질문의 주제에 따른 태그 자동 추출 및 관련 문서 검색
6. 웹 & CLI 인터페이스: 웹 애플리케이션 및 명령줄 인터페이스 제공

## 현재 이슈 및 해결 우선순위

### 주요 이슈

1. 부적절한 응답 생성:
  - 문제: 일부 질문(예: "정법은 불교나 유교와 무엇이 다른가요?")에 관련 없는 내용 제공
  - 원인: 검색 알고리즘이 관련 없는 문서를 반환하거나, 문서 커버리지 부족
2. 임베딩 차원 불일치:

- 오류 메시지: "Embedding dimension 384 does not match collection dimensionality 1536"
- 원인: 내부 임베딩 모델과 벡터 저장소의 임베딩 차원이 일치하지 않음

### 3. 환경 설정 및 의존성 문제:

- 증상: 모듈을 찾지 못하는 오류 등
- 원인: 가상환경 설정 및 패키지 관리의 일관성 부족

## 우선순위 해결 항목

### 1. 임베딩 차원 불일치 해결 (최우선):

- OpenAI text-embedding-ada-002 모델(1536 차원)을 일관되게 사용하도록 코드 수정
- 내부 임베딩 사용 시 차원 호환성 확인

### 2. 검색 품질 개선 (높은 우선순위):

- 질문-문서 관련성 점수 임계값 도입
- 관련 없는 문서가 검색될 경우 적절한 대체 응답 제공
- LLM 프롬프트 개선으로 관련 없는 내용의 요약 제공 방지

### 3. 문서 커버리지 확장 (중간 우선순위):

- 핵심 주제(정법의 특징, 현대 사회 문제 등)에 대한 문서 추가
- 질문-답변 쌍 품질 향상 작업

### 4. 환경 설정 표준화 (중간 우선순위):

- 의존성 관리 개선 (requirements.txt 최신화)
- 설치 및 실행 가이드 문서화

## 향후 개발 로드맵

### 단기 개선 사항 (1-3개월)

#### 1. 검색 및 응답 품질 향상:

- 임베딩 모델 차원 불일치 문제 해결 및 일관된 임베딩 모델 사용 보장
- 하이브리드 검색 구현 (시맨틱 검색 + 키워드 기반 검색)
- LLM 프롬프트 개선: 관련 없는 문서 감지 및 대체 응답 전략 수립
- 검색 결과 필터링 메커니즘 강화: 관련성 점수 임계값 도입

#### 2. 콘텐츠 확충 및 품질 관리:

- 추가 정법 강의 콘텐츠 수집 및 처리
- 주요 질문 카테고리별 문서 커버리지 분석 및 취약 영역 보강
- 고품질 질문-답변 쌍 수동 생성 및 검증
- 테스트 질문 세트 구축 및 정기적 품질 평가

#### 3. UI/UX 개선:

- 모바일 반응형 디자인 적용
- 사용자 피드백 메커니즘 구현 (답변 평가, 문제 보고)
- 관련 질문 버튼 기능 개선
- 검색 실패 시 대체 정보 제공 인터페이스 개선

#### 4. 에러 처리 및 모니터링:

- 상세한 로깅 및 오류 추적 시스템 구축
- 검색 성능 및 응답 품질 지표 개발
- 사용자 질문 패턴 분석 및 학습 피드백 루프 구현

## 중기 개선 사항 (3-6개월)

1. **대화 기억:** 이전 대화 맥락을 기억하고 연속적인 대화 지원
2. **개인화 기능 구현:**
  - 사용자 프로필 및 학습 이력 저장
  - 맞춤형 답변 및 추천 제공
3. **확장된 태그 시스템:**
  - 더 세분화된 주제별 분류
  - 사용자 정의 태그 지원
4. **멀티모달 인터페이스:**
  - 음성 입력/출력 지원
  - 이미지 참조 기능
5. **모바일 최적화:** 다양한 기기에서 최적의 사용자 경험 제공

## 장기 개선 사항 (6-12개월)

1. **자체 모델 개발:**
  - 정법 특화 파인튜닝 모델 개발
  - 지식 그래프 구축 및 통합
2. **커뮤니티 기능:**
  - 사용자 간 대화 및 통찰 공유
  - 집단 학습 경험 제공
3. **플랫폼 확장:**
  - 모바일 앱 개발
  - API 서비스 제공
  - 외부 서비스 연동

## 기대 효과

홍익지기 챗봇은 정법 가르침을 더 많은 사람들에게 접근 가능하게 만들고, 개인의 성장과 자기 이해를 돕는 강력한 도구로 발전할 것입니다:

1. **정법 지식의 확산:** 천공 스승님의 가르침을 디지털 형태로 보존하고 전파
2. **개인 성장 촉진:** 사용자들의 내면 성장과 자기 이해 증진
3. **커뮤니티 형성:** 정법에 관심 있는 사람들의 커뮤니티 형성 촉진
4. **인공지능 기술의 긍정적 활용:** AI 기술을 인간의 영적, 정신적 성장을 위해 활용

## 마치며

홍익지기 프로젝트는 정법 강의 내용을 AI 기술로 더 많은 사람들이 쉽게 접근하고 이해할 수 있

도록 돕는 혁신적인 시도입니다. 현재 핵심 기능 구현을 완료하고 사용자 경험 개선에 집중하고 있으며, 지속적인 개발을 통해 더 유용하고 직관적인 서비스로 발전시켜 나갈 계획입니다.

이 문서는 프로젝트의 현재 상태를 평가하고 미래 발전 방향을 제시하는 살아있는 문서로, 지속적인 개선과 사용자 피드백을 통해 발전해 나갈 것입니다.